

开源齐民项目技术复盘报告

基于 devdocs/ 与当前仓库实现状态的中文技术报告

输出文件: devdocs/tech_report.typ / devdocs/tech_report.pdf

1. 摘要

本报告回顾了“开源齐民”从最初的 LSTM + 注意力 设想，逐步演化为多模型、多阶段验证、长周期风险输出系统的全过程。项目的核心目标始终未变：利用商务预报、全国批发价、天气等多源数据，对山东黄瓜等农产品价格进行可解释的时间序列预测，并在工程上保留面向舆情/政策信号的扩展接口。

从实际研发结果看，项目最大的价值不在于“统一模型在所有周期上全面胜出”，而在于形成了一条验证驱动的迭代路线：先发现 1 日预测的惯性上限，再转向 7/30/90 天多周期；先解决数据口径与省市解析，再优化候选模型、区间校准和风险输出；最后将结果沉淀为 Streamlit 可视化与 PDF 级白底技术文档。当前仓库的最终状态表明，30 天与 90 天预测已经相对季节性基线取得稳定优势，而 7 天预测仍然受到强惯性约束。

项目开发演进时间线




Figure 1: 项目开发演进时间线：从初始方案到 LONG_PERF_3 风险输出。

2. 项目起点：从单模型设想到多源系统

devdocs/1_INITIAL_PLAN.md 给出了项目最初的清晰框架：以山东省黄瓜为例，融合商务部市场价、全国批发价、天气数据，训练一个基于 PyTorch 的 LSTM + 注意力模型，并在架构中预留 sentiment_score / policy_impact 之类的舆情偏置接口。这个阶段的关键贡献有三点：

- 明确了项目并非单纯做价格回归，而是要展示“多源融合 + 可解释预测 + 可扩展政策接口”的完整故事。
- 采用严格按时间切分的数据集划分方式，提前规避了未来信息泄漏。
- 将 Streamlit、README、模型导出、可视化解释一起纳入交付范围，而不是只关注训练脚本本身。

与此同时，devdocs/3_WEATHER.md 让天气接入从“可能可做”变成了一个可靠模块：项目最终选择使用 Open-Meteo 的历史接口，通过多城市代表点构造省级温度和降水特征，并将其统一到日频表中。事实证明，这一步虽然不直接带来显著的 1 日 MAE 改善，但为后续 30/90 天慢变量建模奠定了基础。

3. 数据工程与架构演进

项目最终稳定下来的系统结构，不再是最初单一的“数据 → LSTM”，而是一条更完整的数据工程链路：




Figure 2: 当前仓库中稳定下来的系统架构：从多源采集、对齐、特征工程到短周期/长周期模型与输出层。可以把整个系统拆成四层理解：

3.1. 1. 数据接入层

- swyb/: 负责商务预报价格抓取，后续加入了缓存与重试机制。
- ncpscxx/: 负责全国重点农产品信息平台数据。
- qixiang/: 负责天气抓取，配置化输出到 `data/weather*.csv`。

3.2. 2. 统一清洗层

这一层的最大教训来自真实数据口径：市场名称、县区名称、省市标签都不完全规范。项目后期通过 `cpc` 解析、市场名回退、县区与省份双重解析等方式，逐渐把“山东省黄瓜”这类目标过滤做稳。如果这一层不稳定，后续任何模型结论都不可信。

3.3. 3. 特征工程层

从 `devdocs/4_MORE_MODELS.md` 到 `7_1D_PERF.md` 再到 `11_LONG_PERF_3.md`，特征体系经历了三次扩展：

- 短周期基础特征：滞后、滚动统计、差分、时间编码。
- 长周期补充特征：90 天窗口、季节性、节日距离、长期气象统计、北京销地价格趋势。
- 风险导向特征：极端降温、强降水、节日前置冲击、高动量、价格分位位置等冲击特征。

3.4. 4. 输出与产品化层

项目不再只输出 `csv + metrics.json`，而是逐步形成了：

- 短周期与长周期预测 CSV；
- 候选排行榜与模型摘要 JSON；
- 风险区间和高风险/卖出/避险标记；
- Streamlit 交互页面；
- 面向沉淀与归档的白底 PDF 技术报告。

4. 模型路线：为什么从 LSTM 走向多模型

`devdocs/4_MORE_MODELS.md` 是项目的第一个重要分叉点。它不再假定 LSTM 一定是最优方案，而是将 LightGBM、GRU、LSTM、Prophet 同时纳入比较。这个决策后来被证明非常关键，因为真实结果显示：

- LightGBM 在小样本表格特征上最稳，是后续长期路线的主力。
- GRU / LSTM 提供了序列建模和注意力解释价值，但并未在当前数据规模下形成绝对性能优势。
- Prophet 更适合作为季节趋势分解工具，而不是最终主预测器。

devdocs/5_FEEDBACK.md 则把“模型好坏”从主观感觉变成了明确的工程判断：若某个指标异常好，必须首先怀疑数据泄漏；若 Prophet 明显失利，就应将其定位为解释性辅助，而非继续盲目调参；若训练很快，不应满足于“能跑通”，而应进一步扩展模型路线和误差分析。

这个阶段形成的最重要经验是：**模型比较本身就是产品的一部分**。当仓库能明确说明“某模型为什么不用、另一个模型为什么保留”时，系统的可信度就显著提升。

5. 从 1 日预测到长周期：问题是如何转移的

devdocs/7_1D_PERF.md 和 8_LONG.md 一起定义了项目中期最重要的认知转折：1 日预测几乎被昨日价格的惯性支配，而 7/30/90 天预测才更有机会体现多源特征和建模价值。

从当前仓库的结果可以直观看到这一点：




Figure 3: 不同预测周期相对各自基线的 MAE 比值。1 日与 7 日仍受强惯性约束，而 30/90 日开始体现模型价值。

当前关键结论如下：

- **1 天预测**：LightGBM 与 naive last price 基本持平，说明短周期上限非常低。
- **7 天预测**：最终 mean_blend 仍未超过“当前价直接外推”的基线。
- **30 天预测**：最终 dynamic_blend 的 MAE 比值约为 0.325，已经显著优于季节性基线。
- **90 天预测**：最终 dynamic_blend 的 MAE 比值约为 0.605，说明长周期上模型仍有稳定价值。

也就是说，项目真正有效的方向，不是继续在 1 日预测上做细碎调参，而是把研发资源转移到更长的预测窗口和更稳定的选择逻辑上。

6. 长周期三轮优化：从候选搜索到风险输出

项目的长周期优化不是一次性完成的，而是经历了三轮逐步强化的实验路径。

6.1. 第一轮：LONG_PERF

devdocs/9_LONG_PERF.md 主要解决了两个问题：

- 7 天预测的时间滞后与形状错位；
- 30/90 天预测中趋势与细节难以同时建模的问题。

这一轮落地到仓库后，形成了 `lightgbm_shifted`、`ridge_residual_stack`、`weighted_blend` 等候选，并首次把“候选模型排行榜 + 最终选择”明确写入 `data/model_candidates_long.csv` 与 `data/model_summary_long.json`。

6.2. 第二轮：LONG_PERF_2

`devdocs/10_LONG_PERF_2.md` 进一步引入：

- stacking 与动态权重混合；
- 加权 Huber、更多分位数模型；
- 自适应 conformal / split conformal；
- EVT 尾部建模。

这一轮最重要的经验不是“功能堆得更多”，而是学会了哪些事情必须借助更大样本的 OOF 残差来做：stacking、区间校准、EVT 都不能只盯着很小的验证尾部，否则看起来很先进，实际上统计基础不够稳。

6.3. 第三轮：LONG_PERF_3

`devdocs/11_LONG_PERF_3.md` 将重心从“再加复杂模型”转移到了“提升极端波动响应能力”。实际仓库中最终落地的内容包括：

- 冲击特征：极端降温、强降水、节日前置、高动量；
- 30/90 天目标变化率加权；
- 基于 P25 / P50 / P75 的 quantile-aware dynamic_blend；
- gated residual-corrector 候选；
- 选中结果上的风险区间与高风险/卖出/避险标记。

从候选排行榜看，系统已经不再只是单模型比较，而是一个“候选生成 → 验证选择 → 风险包装”的流程：




Figure 4: LONG_PERF_3 下 30 天与 90 天候选排行榜（按验证 MAE 排序）。

这里最值得总结的经验有三条：

1. 验证优先的选择逻辑比单次测试集偶然提升更重要。例如残差修正器在验证集上可能降低 MAE，但如果触发过于频繁，就会在测试集上造成明显回撤，因此必须加选择护栏。
2. 区间与风险输出需要与点预测解耦。这样即便最终赢家是 `dynamic_blend` 而非某个原始 LightGBM，也可以在选中结果上继续叠加区间校准与风险标记。
3. 极端事件响应并不一定靠更深模型，而常常靠更好的特征和选择准则。LONG_PERF_3 的核心改进恰恰来自冲击特征、权重设计与后处理约束，而非单纯增加模型层数。

7. 可视化与产品化：为什么 Streamlit 仍然重要

仓库的可视化路线也经历了明显的工程演进。早期设想更偏向静态图和训练脚本输出；中期开始转为 Streamlit；后期又逐步聚焦为“长周期 selected-only / selected-plus-risk”的窄而深界面。

从工程角度看，这条路线的价值有三层：

- **验证层**：图表能快速暴露时间错位、字体问题、风险标记异常等问题。
- **解释层**：让“为什么选中这个候选”不再停留在日志和 CSV。
- **交付层**：使项目具备了现场演示和 PDF 归档两种不同传播介质。

当前 LONG_PERF_3 的风险输出已经能以非常直观的方式表达“点预测不一定命中极端值，但区间和风险规则仍有决策价值”：




Figure 5: 30 天与 90 天最终选中方案：实际值、预测值、风险区间与高风险标记。




Figure 6: LONG_PERF_3 选中预测的高风险 / 卖出 / 避险预警占比。

尤其在 90 天窗口上，系统已经不再只是回答“价格会是多少”，而是开始回答“这个窗口风险有多高、是否值得提前预警”。这是项目从“预测器”迈向“辅助决策器”的关键一步。

8. 我们学到了什么

综合 devdocs/、检查点记录和当前实现，可以把这次研发最重要的经验概括为以下几条。

8.1. 1. 先做数据口径治理，再谈模型优劣

省市解析、缺失处理、时间切分、历史样本构造，这些基础工程对结果的影响远大于很多表面上“高级”的模型技巧。若数据口径不稳，任何低 MAE 都可能是幻觉。

8.2. 2. 农产品价格预测必须接受“短周期惯性上限”

1 日与 7 日预测并非完全无价值，但它们的改进空间很有限。真正能体现多源特征和工程投入价值的，是 30 日和 90 日这类慢变量主导的窗口。

8.3. 3. 长周期建模的核心不是单个模型，而是候选系统

相比“找到一个最强模型”，项目更成功的部分其实是：

- 系统化地生成候选；
- 在验证集上比较；
- 将最终选择写回统一的 artifact；
- 在可视化层解释结果。

这种流程比单次调参更容易维护，也更适合继续扩展。

8.4. 4. 风险输出比极端点预测更可靠

LONG_PERF_3 的实践再次证明：极端价格点往往很难被精确点预测命中，但通过区间宽度、高风险标记和规则式预警，系统仍能提供有价值的决策辅助。这比盲目追求某几个极端点的拟合更稳健。

8.5. 5. 工程细节会反复影响最终交付质量

字体兼容、白底/深色双场景可视化、Streamlit 警告、模型导出格式统一 (.pt)、缓存与重试，这些看似“边角料”的工作，实际上决定了项目是否可复现、可展示、可长期维护。

9. 后续工作建议

基于当前状态，后续工作最值得优先投入的方向有三类：

- **更稳的极端事件评估体系**：不仅报告整体 MAE，还单独统计高波动样本、节前样本、冲击特征触发样本上的误差。
- **更可复用的风险规则**：将卖出/避险预警规则进一步参数化，与业务阈值或成本线配置解耦。
- **更完整的报告自动化**：把图表生成、Typst 渲染、artifact 摘要串成一个固定命令，使技术复盘可以和训练流水线一样一键重建。

10. 附录

10.1. A. 关键开发阶段与产出

阶段	代表文档	主要产出与学习
初始方案	1_INITIAL_PLAN.md	确定多源数据、LSTM+注意力、政策接口预留与时间切分原则。
天气与基础数据工程	3_WEATHER.md	确定天气数据来源和省级聚合方式, 为后续长周期特征奠定基础。
多模型扩展	4_MORE_MODELS.md 5_FEEDBACK.md	/ 建立 LightGBM / GRU / LSTM / Prophet 对比框架, 并学会优先排查异常指标与泄漏问题。
短周期优化	6_MODEL_IMP.md 7_1D_PERF.md	/ 完善短周期特征与解释体系, 同时认识到 1 日预测的惯性上限。
长周期初版	8_LONG.md	引入周锚点、90 天历史窗口和 7/30/90 天评估逻辑。
长周期优化一至三	9_LONG_PERF.md 10_LONG_PERF_2.md 11_LONG_PERF_3.md	/ / 形成候选搜索、动态混合、风险输出与最终选择护栏。

10.2. B. 当前关键指标

预测周期	最终方案	测试 MAE	相对基线比值
1 天	LightGBM (与 naive 基本持平)	0.1944	1.001
7 天	mean_blend	0.5681	1.076
30 天	dynamic_blend	0.6915	0.325
90 天	dynamic_blend	1.0359	0.605

10.3. C. 当前仓库中的最终风险输出

预测周期	高风险占比	卖出预警占比	避险预警占比
30 天	0.000	0.960	0.160
90 天	0.212	0.939	0.576

10.4. D. 交付物摘要

- 数据与模型 artifact: data/cleaned_data.csv、 data/model_summary.json、 data/model_summary_long.json、 data/model_candidates_long.csv
- 可视化入口: app.py
- 长周期最终预测: data/predictions/long/h*/selected_{horizon}d_predictions.csv
- 报告源文件: devdocs/tech_report.typ
- 报告图像资源: devdocs/assets/tech_report/*.png

本报告的意义, 不只是记录“项目做了什么”, 更是为后续继续迭代提供一份经过整理的工程记忆: 哪些路线值得继续投入, 哪些路线应当保留为候选而非默认, 哪些问题从一开始就必须通过工程纪律来避免。